



PROYECTO INGENIERIA DE DATOS

Parte 1



UNIVERSIDAD
DE LA FRONTERA

Análisis Epidemiológico mediante Reglas de Asociación en Indicadores de Salud

Julio Contreras, Sebastian Aillapan, Orlando Caullan



Dataset

253.680

registros

21

Columnas

BRFSS

2015

2. Dataset: Origen y Estructura

Origen

Sistema BRFSS 2015 — encuesta telefónica de salud realizada por los Centros para el Control y Prevención de Enfermedades (CDC) de EE.UU. Disponible en Kaggle bajo uso educativo/investigación.

Variables principales

- Hipertensión · Colesterol alto · Tabaquismo
- Actividad física · Enfermedades cardíacas
- Consumo de frutas y vegetales
- BMI · Edad · Educación · Ingresos (continuas/discretas)

La columna de diabetes se trata como característica dentro de la canasta, NO como variable objetivo supervisada.

3. Problema, Pregunta Guía y Usuarios



Problema

En salud pública, los factores de riesgo y patologías coexisten (comorbilidad), pero el gran volumen de datos dificulta identificar combinaciones frecuentes y clínicamente relevantes.

Pregunta guía

¿Cuáles son las combinaciones de comorbilidades y hábitos de vida que coocurren con mayor fuerza estadística y que no son simplemente producto del azar?

Usuarios potenciales



Autoridades de
salud pública



Epidemiólogos
e investigadores



Equipos de
atención primaria
(CESFAM)

4. Método: Reglas de Asociación en Salud



Tipo de tarea: Aprendizaje NO supervisado — Reglas de Asociación (Apriori / FP-Growth)

Si { hipertensión, sobrepeso, colesterol alto } → entonces { antecedente cardíaco }

Support

¿Qué tan común es en la población?

Proporción de registros donde el patrón aparece. Filtra reglas estadísticamente relevantes en la población.

Confidence

Si el paciente tiene A, ¿qué tan seguro es que presente B?

Probabilidad de que, dado A, también aparezca B. Mide la fiabilidad de la regla.

Lift

¿Es una conexión real o es coincidencia por azar?

Lift > 1 confirma que la asociación es más fuerte que el azar. Descarta reglas espurias.



5. EDA y Preparación de Datos

Resultado esperado: dataset
validado listo para Parte 2

Análisis Exploratorio

- Distribución de variables binarias (prevalencia de cada condición).
- Detección de valores faltantes, duplicados e inconsistencias.
- Estadística descriptiva de BMI, edad y outliers.
- Visualizaciones: barras, histogramas, matrices de co-ocurrencia.

Preparación de Datos

- Discretización: BMI $\rightarrow$ bajo peso, normal, sobrepeso, obesidad.
- Edad analizada por rangos etarios.
- Conversión de registros a canastas de características presentes.
- Foco en valores positivos: evita reglas triviales (ej. no fumar $\leftrightarrow$ no colesterol alto)